

やったこと

Model	Input	Problem Addressed	Description
DQN	s_t	model-free MDP	full knowledge of the state required
DBQN	b_t	model-based POMDP	updated belief state required
DRQN	$\langle o_1, o_2, \dots, o_t \rangle$	model-free POMDP	observations as the input
DDRQN	$\langle a_0, a_0, \dots, a_{t-1} \rangle$ $\langle o_1, o_2, \dots, o_t \rangle$	model-free POMDP	decoupled actions and observations required
ADRQN	$\langle \langle a_0, o_1 \rangle, \langle a_1, o_2 \rangle, \dots, \langle a_{t-1}, o_t \rangle \rangle$	model-free POMDP	action-observation pairs required as input

Table 1: A comparison among state-of-the-art deep Q-learning approaches

先週実装できていなかったDBQN、ARDQNを実装+プログラムの修正を行った。

DBQNの実装

DBQNでは、能力の事後分布 $p(\theta \mid \text{回答履歴})$ である belief をQネットワークの入力とする。

=> belief を離散化してベクトルにした。

```
$$
\theta \in [-4,4]
$$

をK点に分割します。

$$
\theta_1, \theta_2, \ldots, \theta_K
$$
```

このとき belief は、

```
$$
b_t =
\begin{bmatrix}
p(\theta_1 \mid H_t) \backslash \\
p(\theta_2 \mid H_t) \backslash \\
\vdots \backslash \\
p(\theta_K \mid H_t)
\end{bmatrix}
$$
```

という K 次元ベクトルになる。

ここで H_t は、それまでの出題・回答履歴。

```
$$
H_t = \{(i_1, u_1), (i_2, u_2), \ldots, (i_t, u_t)\}
$$
```

初期belief $b_0(\theta)$ は

$$b_0(\theta_k)$$

$$\frac{\mathcal{N}(\theta_k; 0, 1)}{\sum_{j=1}^K \mathcal{N}(\theta_j; 0, 1)}$$

項目 i_t を出題し、回答 u_t が得られたら、Bayes更新します。

$$b_{t+1}(\theta_k)$$

$$\frac{P(u_t \mid \theta_{k,i_t}) b_t(\theta_k)}{\sum_{j=1}^K P(u_t \mid \theta_{j,i_t}) b_t(\theta_j)}$$

このとき、報酬は、**事後分散減少を報酬** に用いた

$$r_t$$

$$\mathrm{Var}_{b_t}(\theta)$$

$$\mathrm{Var}_{b_{t+1}}(\theta \mid u_t)$$

すなわち、

$$r_t$$

$$\sum_{k=1}^K b_t(\theta_k) \left(\theta_k - \mu_t \right)^2$$

$$\sum_{k=1}^K b_{t+1}(\theta_k \mid u_t) \left(\theta_k - \mu_{t+1}(u_t) \right)^2$$

である。

性能比較

