

回答履歴を考慮した強化学習に基づく適応型テスト

Adaptive Testing Based on Reinforcement Learning Considering Response History

柴沼 巖 宇都 雅輝

電気通信大学

The University of Electro-Communications

Abstract:

項目反応理論 (Item Response Theory: IRT) に基づくコンピュータ適応型テスト (Computerized Adaptive Testing: CAT) では, 受検者の能力推定の効率性が項目選択手法に強く依存する. 一般的な項目選択手法としてはフィッシャー情報量最大化による方法が知られているが, 近年, 深層強化学習を用いた Deep Q-Network (DQN) に基づく項目選択手法が提案され, 能力推定の精度と効率性の改善が報告されている. しかし, 従来の DQN に基づく手法では, 強化学習の状態変数として現時点での能力推定値のみを用いるため, 受検者のこれまでの回答パターンに含まれる情報を十分に活用できていない. そこで本研究では, DQN に基づく CAT を再定式化し, 受検者の回答履歴を状態として利用する Deep Recurrent Q-Network に基づく項目選択戦略を提案する. シミュレーション実験の結果, テスト全体わたる RMSE の平均値において提案手法は従来手法を上回る数値を示した.

1 はじめに

コンピュータ適応型テスト (Computerized Adaptive Testing: CAT) は, 出題される項目が受検者の回答行動に応じて適応的に変化するテスト方式であり, コンピュータを用いた試験 (Computer-based Testing) において広く利用されている. 一般に CAT は項目反応理論 (Item Response Theory: IRT) の利用を前提に設計されることが多い [1]. IRT に基づく CAT では, 受検者に項目を出題して反応データが得られるために, IRT に基づいて受検者の能力を推定し, その能力に適した項目が次の項目として選択・出題される. このような適応的な出題機構により, CAT は従来の固定項目型のテスト形式と比べて, より少ない項目数で受検者の能力を高精度に推定できる利点を有する [2, 3].

他方で, CAT における能力測定の効率性は, 項目選択手法に強く依存するため, その手法開発が重要な研究テーマとなる. 最も標準的な項目選択手法としては, フィッシャー情報量を最大化する項目を選択する最大フィッシャー情報量手法 (Maximum Fisher Information: MFI) が知られている [4]. MFI は現在の能力推定値に対する漸近誤差分散の逆数を最大化するという原理に基づくが, 暫定の能力推定値が真の能力値から大きく乖離している場合などでは, 適切な項目を選択できないといった問題が知られている [5]. 他方で, この問題への対処

を目的として, 尤度重み付きフィッシャー情報量 (Fisher Information Weighted by the Likelihood: FIWL) [6] や, 尤度重み付き Kullback-Leibler 情報量 (Kullback-Leibler information weighted by the Posterior: KLP) [5] などに基づく項目選択手法も提案されてきた.

しかし, このような従来の項目選択手法には, 共通する二つの課題が残る. 一つ目の課題としては, 全体最適ではなく局所最適な項目選択を行う点が挙げられる. これは, 次の 1 項目の選択行動のみを最適化対象としており, その先の項目選択全体の影響が考慮されないために生じる課題である. 二つ目の課題は, 項目選択の方略をデータドリブンで柔軟に構築できない点である. 対象の項目集合に対する過去の受検者集団の反応データが得られる場合, そのデータを用いて能力推定の効率や精度を最大化する項目選択方略を設計できる可能性があるが, それらが MFI や FIWL, KLP などに基づく選択手法と一致する保証はない.

これらの課題を解決するアプローチの一つとして, 近年, 強化学習に基づく項目選択手法が提案されている [7, 8, 9, 10]. これらの手法では, 過去の項目反応データから動的に項目選択方略を学習できるとともに, 将来の項目選択全体で得られる情報量の期待値を最大化するように項目を選択するため, 局所最適に留まらない項目選択が可能となる. 強化学習に基づく最新の項目選択手法の一つとして, Wang et al. [10] は深層

強化学習を用いた Deep Q-Network (DQN) に基づく項目選択手法を提案している。この手法では、項目選択問題をマルコフ決定過程 (Markov Decision Process: MDP) として定式化し、DQN による Q 関数 (行動価値関数) の近似を通して、項目選択を実現している。シミュレーション実験と実データ実験において、この手法は MFI をはじめとする従来手法より高性能を達成している。

しかし、上記の DQN に基づく従来手法では、DQN 内で状態変数として扱われる情報が、IRT に基づく 1 次元の能力推定値のみとなっており、当該受検者のそれまでの項目反応履歴が利用できない。これは、過去の項目反応履歴が 1 次元の能力推定値に集約的に表現可能な場合 (言い換えると、能力推定に利用している IRT モデルが項目反応行動を完全に説明可能な場合) には妥当であるが、そうでない場合には、能力推定値に集約できない項目反応情報を取りこぼしてしまい、そのことが学習される項目選択方略の性能に影響を与える可能性がある。そこで本研究では、この課題を解決するために、CAT を受検者の項目反応履歴を状態とした MDP として再定式し、Deep Recurrent Q-Network (DRQN) による Q 関数近似に基づいて項目反応履歴を考慮した項目選択を実現する手法を提案する。

2 項目反応理論に基づくコンピュータ適応型テスト

本節では、IRT に基づく CAT の一般的な方法論について概説する。

2.1 IRT モデル

本研究では、CAT において能力推定や項目選択に使用される IRT モデルとして、代表的な二値反応モデルの一つである 3 パラメータロジスティックモデル (3PLM) の利用を想定する。3PLM では項目 i に対する受検者の正答確率を次式で定義する。

$$P_i(\theta) = c_i + \frac{1 - c_i}{1 + \exp[-a_i(\theta - b_i)]} \quad (1)$$

ここで、 θ は受検者の能力、 a_i は識別力パラメータ、 b_i は困難度パラメータ、 c_i は推測パラメータを表す。以降では、 a_i 、 b_i 、 c_i を合わせて項目特性値と呼ぶ。

CAT では、項目特性値が予め推定された項目集合 (項目バンクと呼ぶ) を用意しておき、そこから受検者にあった項目を適応的に出題する。具体的には、受検

者に項目を出題して回答が得られるたびに、IRT に基づいて受検者の能力を推定し、その能力に適した項目を次の項目として選択・出題する。なお、項目バンク中の項目特性値の推定は、事前テストなどを通して得られた項目反応データから、周辺最尤推定法などで行われることが一般的である。また、CAT の過程での能力の逐次推定には、最尤法やベイズ推定法が採用されることが一般的である。

2.2 フィッシャー情報量最大化に基づく項目選択手法

項目選択は CAT による能力推定の効率性や精度に強く影響する中核的な機構として位置付けられる。代表的な手法である MFI では、フィッシャー情報量を最大化するように項目を選択する。ここで、3PLM を前提とすると、項目 i に対するフィッシャー情報量は次式で定義される。

$$I_i(\theta) = \frac{a_i^2(1 - c_i)}{[c_i + \exp(a_i(\theta - b_i))][1 + \exp(-a_i(\theta - b_i))]^2} \quad (2)$$

したがって、 $l-1$ 項目出題した時点での受検者の能力推定値を $\hat{\theta}_l$ 、その時点での未出題の項目集合を B_l とすると、MFI に基づく l 項目目の項目選択方略は次式で定義される。

$$i_l = \operatorname{argmax}_{i \in B_l} I_i(\hat{\theta}_l) \quad (3)$$

しかし、MFI ではテスト初期などの暫定の能力推定値が真の能力値から大きく乖離している場合には適切な項目を選択できない可能性がある。この問題への対処として FIWL の積分値を最大化するような項目を選択する項目選択手法も提案されている [6]。

しかし、1 章で述べた通り、このような従来の項目選択手法の課題として、1) 局所最適な選択に陥る点と、2) 項目選択の方略をデータドリブンで柔軟に構築できない点が残る。他方で、これらの課題を解決するアプローチとして、強化学習に基づく項目選択手法が提案されている [7, 8, 9, 10]。次節では、最新の手法の一つであり、本研究のベースラインとする Wang et al. [10] の手法を紹介する。

2.3 強化学習に基づく項目選択手法

強化学習とはエージェントが環境と相互作用しながら、将来にわたる報酬の重み付き和を最大化するような方策を学習する枠組みである。方策とは、現在の状

態に基づいてどのような行動を行うかを確率的に定めるものであり、エージェントとは現在の状態と方策に基づき行動を選択するものである。環境とはエージェントの行動・状態に基づき報酬と次状態を決定するものである。

強化学習において、環境は数理モデルによって記述される。そこで Wang ら [10] は、CAT の項目選択問題を MDP として定式化した。MDP は逐次意思決定問題の数学的枠組みとして広く用いられる、次の状態は現在の状態と行動によってのみ決まるというマルコフ性を仮定したモデルである。Wang ら [10] は、MDP を用いて項目選択問題を次のように定式化した。

- 状態：現在の能力推定値 $\hat{\theta}_l$
- 行動：次に出題する項目 ($i_l \in B_l$) の選択行動
- 報酬：項目 i_l のフィッシャー情報量 $I_{i_l}(\theta)$
- 環境：IRT に基づく受検者の回答生成と能力推定

強化学習で広く使われるアルゴリズムの一つである Q 学習は方策を直接学習するのではなく、Q 関数と呼ばれる特定の状態においてある行動を取ったときに得られる期待報酬の総和を表す関数を学習することで最適な方策を導出するアルゴリズムである。

Q 関数は式 (4) で定義される。

$$Q^\pi(\hat{\theta}_l, i_l) = \mathbb{E}_\pi \left[I_{i_l}(\hat{\theta}_l) + \sum_{k=l+1}^L \gamma^{k-l} I_{i_k}(\hat{\theta}_k) \mid \hat{\theta}_l, i_l \right] \quad (4)$$

ここで γ は割引率、 L はテスト長である。また Wang ら [10] は、この Q 関数をニューラルネットワークで近似する Deep Q-Network (DQN) [11] を用いて、項目選択方略を学習する手法を提案した。DQN とは、モデルへの入力を状態とし、式 (5) の損失関数を最小化することで Q 関数を近似するアルゴリズムである。

$$\mathcal{L} = \left[r_l + \gamma \max_{i \in B_{l+1}} Q_{\text{target}}(s_{l+1}, i; \theta') - Q_{\text{action}}(s_l, i_l; \theta) \right]^2 \quad (5)$$

[前の説明とここからの説明にギャップがある。Q 関数の導入が唐突すぎる。また Q 関数を定義して終わりでは意味不明なので、よくわからないので、全体像との対応関係がより明確になるように Q 関数の役割と説明を書き直すこと。つまり、どのようにこの Q 関数を含めた全体の最適化がなされるのかの説明が必要であるということです。3.3 ほど具体的でなくていいが、

使用されるアルゴリズムとその概要的な考え方だけ簡潔に述べること。]

そして方策には確率 $1-\varepsilon$ で最大の Q 値を持つ項目を選択し、確率 ε でランダムに項目を選択する ε -greedy 法が用いられた。

他方で、この DQN に基づく手法は、状態が IRT に基づく 1 次元の能力推定値のみとなっており、当該受検者のそれまでの項目反応履歴は利用できないという課題を有する。これは、過去の項目反応履歴が 1 次元の能力推定値に集約できる、すなわち、能力推定に利用している IRT モデルが項目反応行動を完全に説明可能な場合には妥当であるが、そうでない場合には、有益な情報を取りこぼす可能性があり、そのことは学習される項目選択方略の性能に影響を与える。

3 提案手法

本研究では、上記の課題を解決するために、各受検者の項目反応履歴に基づいて項目選択を実現する強化学習ベースの項目選択手法を提案する。具体的には、MDP における状態を受検者の項目反応履歴として再定式し、Q 関数の近似に DRQN を用いることで、受検者の回答履歴を考慮した項目選択を実現する。

3.1 DRQN による Q 関数の近似

Wang ら [10] と同様に、本研究においてもニューラルネットワークを用いて Q 関数を近似することを考える。しかし、Wang ら [10] らの定式化では状態が能力推定値という非系列的な情報であったのに対し、本研究では状態を受検者の項目反応履歴という系列的な情報として再定式した。そこで本研究では、項目反応履歴を状態として再定式した MDP を解くために、Hausknecht と Stone [12] が提案した DRQN を用いる。DRQN は DQN の最初の全結合層を LSTM に置き換えたアーキテクチャであり、これまでの受検者の回答系列に基づいて各項目の Q 関数の推定を行うことができる。

本研究における DRQN のアーキテクチャは以下の構成である。

1. Embedding 層：回答を 3 カテゴリー (0: 誤答, 1: 正答, 2: 開始トークン) の埋め込み表現に変換する。
2. LSTM 層：埋め込み系列を逐次処理し、隠れ状態を更新する。

3. 全結合出力層：LSTM の出力からアイテムバンク内の全項目に対する Q 値を出力する。

本研究にて使用する DRQN のアーキテクチャを図 1 に示す。図 1 から分かるように、DRQN において埋め込み表現に変換された項目反応履歴は LSTM で逐次処理される。これにより、受験者の項目履歴を LSTM が内部状態として保持することでこれまでの回答履歴に基づいた Q 関数の推定を行うことができる。

次節にて、DRQN の学習アルゴリズムについて説明する。

3.2 学習アルゴリズム

先行研究 [12] に倣い DRQN の学習には、安定化を目的に 経験再生 (Experience Replay) という手法を用いる。経験再生とは、DRQN で近似された Q 関数の値と ϵ -greedy 法によって生成された項目反応履歴、選択された項目、報酬の系列の 3 つの情報をリプレイメモリに蓄積した後、ランダムサンプリングして損失関数を最小化することでネットワークのパラメータを更新する手法である。DRQN はエピソード単位、すなわち 1 人の受験者のテスト全体を 1 エピソードとしてネットワークのパラメータを更新する。ただし、推論時には項目反応履歴を 1 ステップずつ DRQN に入力し、各ステップでの Q 値を計算することで次の項目選択を行う。また、方策には Wang ら [10] と同様に ϵ -greedy 法を用いる。

学習の手順は以下の様にまとめることができる。

1. 学習用の真の特性値 $\theta_n \sim N(0, 1)$ ($n = 1, \dots, N_{\text{training}}$) を事前に一括生成する。
2. 受験者 $n = 1, \dots, N_{\text{training}}$ について順に、以下のシミュレーションを行いエピソードを生成する。
 - (a) 各決定ステップ $l = 1, \dots, L$ において、DRQN によって近似された Q 関数の値と ϵ -greedy 法を用いて未出題項目から項目 i_l を選択する。
 - (b) 3PLM に基づき、真の特性値 θ_n を用いて回答 $o_l \in \{0, 1\}$ を確率的に生成する。
 - (c) 報酬 $r_l = I_{i_l}(\theta_n)$ を、真の特性値 θ_n におけるフィッシャー情報量として計算する。

1 エピソード分の回答系列・行動系列・報酬系列をリプレイメモリに保存する。

3. リプレイメモリに m 件以上のエピソードが蓄積されたら、 m 件のミニバッチをサンプリングし、式 (5) の損失関数で Q-Network のパラメータを更新する。 τ 回の更新ごとにターゲットネットワークのパラメータを同期する。

4. 手順 2~3 を N_{training} 回繰り返す間、一定間隔でバリデーションを行い、最良モデルを保存する。

4 シミュレーション実験

4.1 実験設定

アイテムバンクの生成 Wang ら [10] のシミュレーション設定に基づき、各アイテムバンクを 200 項目で生成した。項目パラメータの分布は以下の通りである。

- 識別力： $a \sim N(1.2, 0.25)$ ($a > 0$)
- 困難度： $b \sim N(0, 1)$
- 疑似推測： $c \sim N(0.25, 0.02)$ ($0 < c < 1$)

項目のパラメータ a と b は通常相関していることを考慮しパラメータ間に相関のないアイテムバンク（無相関アイテムバンク, $r_{ab} = 0$ ）と相関のあるアイテムバンク（相関アイテムバンク, $r_{ab} = 0.5$ ）の 2 種類を各 3 バンク、計 6 バンク生成した。各バンクに対して、5000 名の受験者の真の特性値を標準正規分布 $N(0, 1)$ から生成し各手法の性能評価に用いた。

比較手法 本研究では MFI [4], DQN [10], DRQN (提案手法) [12] の 3 手法を比較する。ただし、DQN は学習用の真の特性値を一様分布から生成したもの (DQN_uniform) と正規分布から生成したもの (DQN_normal) の 2 種類を用意し、DRQN の学習には一様分布のみを使用した。

評価指標 シミュレーション実験にて以下の 2 つの指標を用いて、各手法の推定精度を評価する。

$$\text{Bias} = \frac{1}{N} \sum_{n=1}^N (\hat{\theta}_n - \theta_n) \quad (6)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{n=1}^N (\hat{\theta}_n - \theta_n)^2} \quad (7)$$




図 1: DRQN のアーキテクチャ.




図 2: 各ステップにおける RMSE の推移 (無相関バンク・有相関バンク, バンク 1~3 平均)

4.2 結果

無相関アイテムバンク ($r_{ab} = 0$) と相関アイテムバンク ($r_{ab} = 0.5$) の各ステップにおける RMSE, Bias の平均値を図 23 に示す。

図 3 から分かるように、テスト初期の 10 ~ 15 問目において提案手法は無相関アイテムバンクで RMSE が DQN_normal と比較して最大 43% 改善 (DQN_uniform と比較して最大 60%改善) し、相関アイテムバンクで RMSE が DQN_uniform と比較して最大 35% 改善 (DQN_normal に比べて最大 55%改善) するなど、提案手法はテスト初期において既存手法の DQN よりも大幅に精度が高いことが確認できる。

また、テスト全体における平均 RMSE を見ると無相関アイテムバンクでは提案手法は DQN_uniform に比べて 約 10% の改善を示し、DQN_normal とは同

程度の精度を示した。相関アイテムバンクにおいては提案手法 DQN_uniform を約 14%上回る精度を示し、DQN_normal を約 5%上回る精度を示した。

5 おわりに

本研究は、IRT に基づく CAT の項目選択を Wang ら [10] の定式化における状態を受験者の回答履歴に置き換える形で再定式し、Q 関数を DRQN で近似する手法を提案した。3PLM によって生成されたシミュレーションデータを用いて既存手法と提案手法の比較を行った結果、テスト全体における平均 RMSE は提案手法が既存手法の DQN を約 5~14%上回る精度を示した。特に、テスト初期の 10 ~ 15 問目において既存手法を大きく上回る性能を示した。本研究での提案手法は、項




図 3: 各ステップにおける Bias の推移（無相関バンク・有相関バンク、バンク 1~3 平均）

目パラメータも状態に組み込むことで 項目パラメータを考慮したモデルへ拡張することも可能である。さらに、本研究ではシミュレーション実験において提案手法の性能を評価したが、今後は実データを用いた実験による性能の検証も必要である。

参考文献

- [1] Wim J. van der Linden. *Handbook of Item Response Theory*. CRC Press, 2016.
- [2] Andreas Frey. Computerized adaptive testing. In Robert J. Mislevy and Hong Jiao, editors, *The Oxford Handbook of Educational Assessment*. Oxford University Press, 2023.
- [3] Howard Wainer, Neil J. Dorans, Daniel Eignor, et al. *Computerized Adaptive Testing: A Primer*. Erlbaum, 2 edition, 2000.
- [4] Frederic M. Lord. *Applications of Item Response Theory to Practical Testing Problems*. Erlbaum, 1980.
- [5] Hua-Hua Chang and Zhiliang Ying. A global information approach to computerized adaptive testing. *Applied Psychological Measurement*, Vol. 20, No. 3, pp. 213–229, 1996.
- [6] Wim J. J. Veerkamp and Martijn P. F. Berger. Some new item selection criteria for adaptive testing. *Journal of Educational and Behavioral Statistics*, Vol. 22, No. 2, pp. 203–226, 1997.
- [7] Aritra Ghosh and Andrew Lan. BOB-CAT: Bilevel optimization-based computerized adaptive testing, 2021. arXiv preprint arXiv:2108.07386.
- [8] Darkhan Nurakhmetov. Reinforcement learning applied to adaptive classification testing. In Bernard P. Veldkamp and Cor Sluijter, editors, *Theoretical and Practical Advances in Computer-based Educational Measurement*, pp. 325–336. Springer, 2019.
- [9] Jae Shin and Okan Bulut. Building an intelligent recommendation system for personalized test scheduling in computerized assessments: A reinforcement learning approach. *Behavior Research Methods*, Vol. 54, No. 1, pp. 216–232, 2022.
- [10] Peng Wang, Hao Liu, and Mingzhe Xu. An adaptive testing item selection strategy via a deep reinforcement learning approach. *Behavior Research Methods*, Vol. 56, pp. 8695–8714, 2024.
- [11] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, et al. Human-level control through deep reinforcement learning. *Nature*, Vol. 518, No. 7540, pp. 529–533, 2015.
- [12] Matthew Hausknecht and Peter Stone. Deep recurrent Q-learning for partially observable MDPs, 2015. arXiv preprint arXiv:1507.06527.